RAPORT PROJEKTOWY

Temat: Empiryczna analiza złożoności obliczeniowej mnożenia macierzy
Autor: Jakub Furmanek

1. WPROWADZENIE

Celem niniejszego projektu jest empiryczna weryfikacja teoretycznej złożoności obliczeniowej algorytmu mnożenia macierzy gęstych. Teoretyczna złożoność dla standardowego algorytmu mnożenia macierzy o wymiarach p na q i q na r wynosi O(pqr). W eksperymencie zmierzono rzeczywisty czas wykonywania operacji mnożenia w bibliotece NumPy dla różnych kombinacji wymiarów, a następnie dopasowano modele regresyjne, aby sprawdzić, w jakim stopniu teoria pokrywa się z praktyką na współczesnej architekturze komputerowej.

2. USTAWIENIA EKSPERYMENTU

Środowisko sprzętowe i programowe:
- MacBook Air M2: Apple M2, 16 GB RAM, SSD 256 GB
- Oprogramowanie: Python 3.12.7., Visual Studio Code

Procedura pomiarowa: Do mnożenia macierzy wykorzystano operator @ (funkcja numpy.matmul). Macierze wypełniono losowymi wartościami z rozkładu jednostajnego.

Zakres danych: Wybrano wymiary macierzy z zakresu od 100 do 1500. Decyzja ta podyktowana była chęcią zbadania wydajności zarówno dla małych problemów (mieszczących się w cache procesora), jak i większych, wymagających dostępu do RAM.

Powtarzalność: Każdy punkt pomiarowy powtórzono 5 razy. Jest to kompromis pozwalający na uzyskanie stabilnych wyników przy akceptowalnym czasie trwania eksperymentu.

Metryki: Rejestrowano czas średni, odchylenie standardowe oraz medianę. Do modeli regresyjnych wykorzystano medianę czasu, aby zminimalizować wpływ chwilowych opóźnień systemu.

3. METODY

W celu analizy zależności czasu obliczeń (T) od rozmiaru problemu (p, q, r), zastosowano analizę regresji. Dopasowano trzy modele:
Model 1: Log-liniowy (pełny) log(T) = alpha + beta_p * log(p) + beta_q * log(q) + beta_r * log(r) + ε. Model ten bada niezależny wpływ każdego wymiaru na czas wykonania.

Model 2: Logarytmiczny (złożoność teoretyczna) log(T) = alpha + beta * log(p * q * r) + ε. Model zakłada, że czas zależy bezpośrednio od liczby operacji zmiennoprzecinkowych.

Model 3: Liniowy (dane surowe) T = alpha + gamma * (p * q * r) + ε. Model weryfikujący liniową zależność czasu od rozmiaru zadania bez transformacji logarytmicznej.

4. WYNIKI

Poniżej przedstawiono parametry wyznaczonych modeli regresyjnych na podstawie zebranych danych:
Model 1 (Log-liniowy):
R-kwadrat (dopasowanie): 0.9897
Współczynniki: beta_p = 0.86, beta_q = 0.89, beta_r = 0.93

Model 2 (Log pqr):
R-kwadrat (dopasowanie): 0.9894
Współczynnik: beta = 0.89

Model 3 (Liniowy surowy):
R-kwadrat (dopasowanie): 0.9919
Współczynnik gamma: 1.49e-11 (czyli 0.0000000000149)
Wyraz wolny (intercept): 0.0011 s

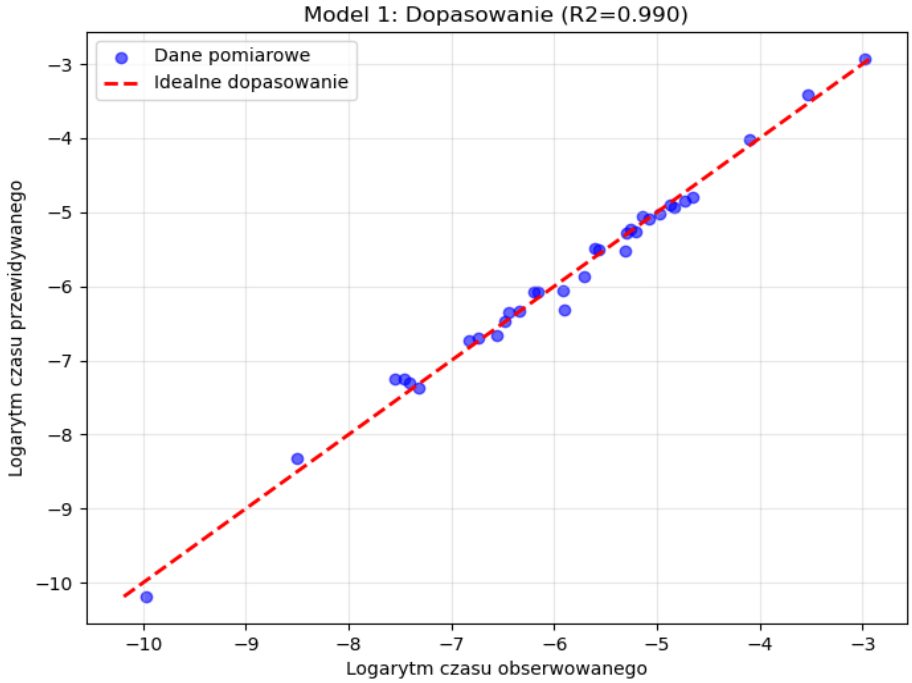

Rys 1. Porównanie wartości przewidywanych przez Model 1 z wartościami rzeczywistymi.

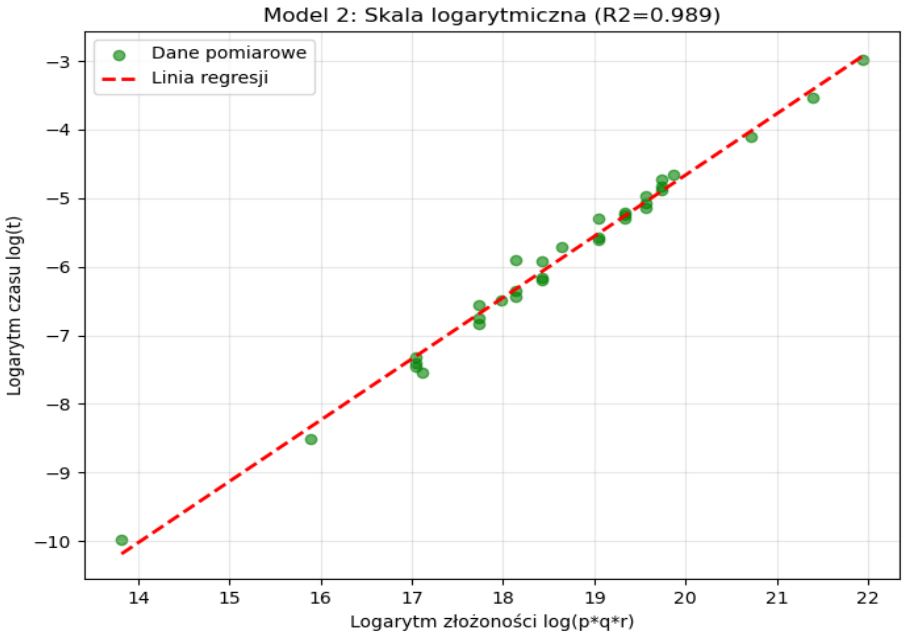

Rys 2. Zależność czasu od złożoności w skali logarytmicznej (Model 2).

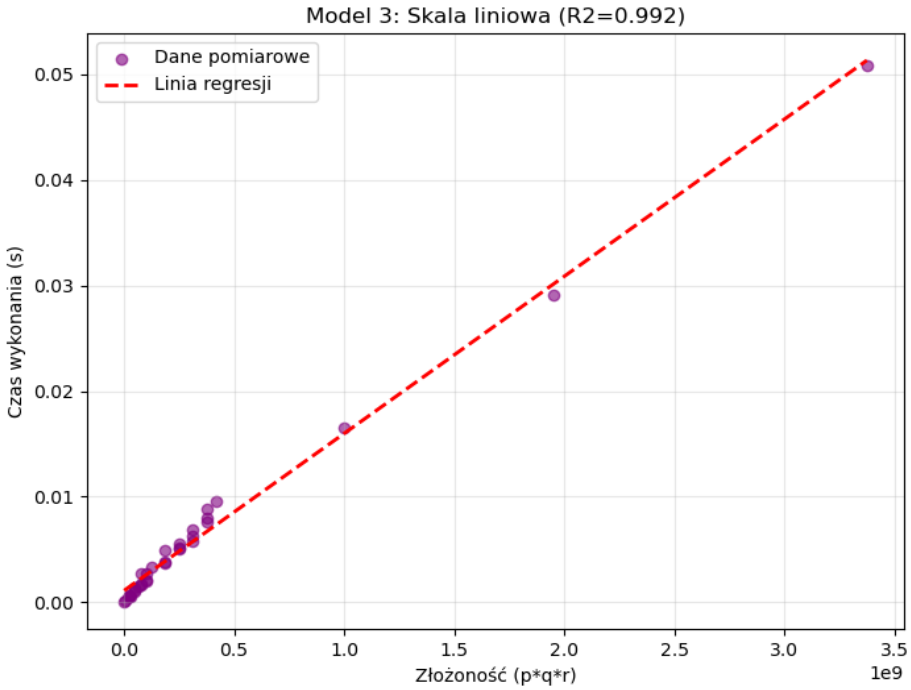

Rys 3. Zależność czasu wykonania od złożoności obliczeniowej w skali liniowej (Model 3).

5. DYSKUSJA

Analiza wykładników: W Modelu 2 współczynnik przy logarytmie pqr wynosi 0.89. Jest to wartość bliska 1.0, ale nieco niższa, co wskazuje na bardzo dobrą skalowalność biblioteki NumPy w badanym zakresie. Złożoność jest nieco lepsza niż pesymistyczne O(n^3), co wynika z optymalizacji blokowych i wektorowych.

Wpływ wymiarów: W Modelu 1 współczynniki są do siebie zbliżone (0.86 - 0.93), co sugeruje zbalansowany wpływ każdego wymiaru. Największy wpływ w tym eksperymencie wykazał wymiar r (0.93), a najmniejszy wymiar p (0.86). Oznacza to, że wzrost liczby kolumn w drugiej macierzy miał relatywnie największe przełożenie na wzrost czasu wykonania.

Porównanie modeli: Model liniowy (Model 3) osiągnął najwyższy współczynnik determinacji R-kwadrat równy 0.9919. Jest to wynik lepszy niż dla modeli logarytmicznych (ok. 0.989). Oznacza to, że prosta zależność liniowa od iloczynu pqr (z bardzo małym wyrazem wolnym ok. 0.001 s) najlepiej opisuje zachowanie algorytmu dla macierzy do rozmiaru 1500 na 1500.

6. WNIOSKI

Eksperyment wykazał, że czas mnożenia macierzy w NumPy rośnie w sposób wysoce przewidywalny. Najlepszym modelem okazał się Model 3 (Liniowy), co potwierdza bezpośrednią zależność czasu od liczby wykonanych operacji zmiennoprzecinkowych. Z kolei analiza modeli logarytmicznych ujawniła, że rzeczywista złożoność w badanym środowisku wynosi około O((pqr)^0.89), co świadczy o efektywnym wykorzystaniu mechanizmów optymalizacyjnych procesora (pamięć cache, instrukcje wektorowe) przez bibliotekę BLAS, która "ukrywa" część kosztów teoretycznych.